AI PDF Import 生产变更报告

项目: o2iinstitute | 分支: someone114514/ai-pdf-import-hardening | 日期: 2026-06-07

1. 变更概览

本次变更新增并加固管理端 AI PDF Import 能力。管理员可以先上传 PDF 源文件，系统保存导入批次和源资产；随后管理员选择已启用的模型服务执行 AI 提取。提取结果会转换为现有批量导入的数据结构，并创建草稿题目。题目发布流程不变，仍由 Review Drafts 和人工审核控制。

变更重点包括 PDF 源文件资产归属、AI 提取任务生命周期、模型输出容错、失败恢复、题目编辑器预览兼容，以及普通题目 source PDF 上传失败后的清理。这些调整的目标是让导入过程可观察、可恢复，并与当前题库导入、审核和发布体系保持一致。

2. 业务功能变更

2.1 PDF 源文件上传与管理

- AI PDF Import 页面支持管理员上传 PDF 源文件，上传动作不依赖 AI provider 是否已经配置。
- 上传完成后，系统创建 ai_pdf import batch，并将 PDF 保存为导入级 source asset。
- 原始 PDF 不绑定到具体题目，不进入公开题目详情页。
- 页面显示 source PDF、batch 状态、asset 状态、已创建题目数、warnings 和错误信息。
- source PDF 可在安全状态下删除；运行中的 batch 不允许删除源文件。

2.2 AI 提取与状态反馈

- 管理员选择 enabled provider 后启动 AI extraction。
- 系统记录 jobId 和 lease 信息，降低重复点击、双 tab 或并发启动造成的重复导入风险。
- 页面在提取期间显示运行状态、阶段说明和轮询日志，包括读取 PDF、加载 provider、加载 tags、准备输入、调用 provider、校验回复、创建题目和裁图等阶段。
- provider 请求失败、JSON 校验失败或后处理失败时，batch 会记录失败状态和错误详情。

2.3 审核发布流程

- AI 提取结果只创建 draft questions，不自动发布。
- AI 输出会转换为现有 Batch Import normalized questions，并复用 importBatchImportJson 创建题目。
- Review Drafts 和 Admin Questions 仍作为人工检查入口，管理员可以修改题干、解析、标签、图片资产和发布状态。
- AI 新增或复用的标签仍需由管理员判断是否合适；发布题目仍由现有流程控制。

2.4 图片和编辑器兼容

- AI 裁图后确认属于某道题的图片继续创建 question_assets，保留现有预览、删除、显示和隐藏能力。
- 如果 AI 返回的图片 placeholder 没有出现在正文 HTML 中，系统保留图片资产并记录 warning。
- RichHtml 增加 legacy raw dollar math 兼容，旧 AI 内容中的 $...$ 会在预览和公开展示中渲染为 KaTeX。
- Advanced HTML 模式现在显示真实 content_html，而不是 content_source。

3. 流程兼容性

流程	兼容方式
JSON Import	主流程不变，继续通过现有 preview/import 创建 draft questions。
Package Import	主流程不变，本次不强制迁移 package 内部资源管理。
Bulk Asset Upload	继续用于给既有题目补充图片/PDF，不触发 AI。
AI PDF Import	AI 输出转换为 normalized import JSON 后复用现有导入服务。
Review Drafts	AI PDF 创建的题目进入同一审核队列，发布逻辑不分叉。
Public Question Detail	仅展示已发布题目和允许展示的 question_assets；source PDF 不公开。

4. 资产归属与生命周期

4.1 资产归属

资产类型	归属	用途
原始 AI PDF	import_batch_assets	记录导入来源，供 AI 提取和审计使用。
AI 临时裁图候选	import_batch_assets 或后处理上下文	可作为后续导入级资产工作区扩展。
最终题目图片	question_assets	在题目详情页展示、预览、删除、显示或隐藏。
普通题目 source PDF	question_source_files	人工给单题绑定来源文档，不公开展示。

4.2 Batch 状态

状态	含义	处理方式
draft	PDF 已上传或 batch 已创建，尚未开始 AI 提取。	可以选择 provider 启动提取；通常可以删除 source。
validating / queued	提取请求已进入队列，等待 leased job 执行。	不允许删除 source。
validating / calling_provider	正在调用模型。	页面显示运行状态和轮询日志。
failed	提取、校验、导入或后处理失败。	查看错误；无题目时可重试，有题目时先 reset outputs。
imported	draft questions 已创建。	进入 Review Drafts 或 Admin Questions 人工修订。

4.3 失败恢复

- 上传失败时，系统按 uploadAttemptId 取消 pending asset，避免残留不可用记录。
- provider 失败时，系统保留 source PDF 和错误详情，便于后续换 provider 或重试。
- AI 输出不符合 schema 时，系统保留 response preview，并带错误路径请求模型修复一次。
- AI 已创建 draft 但结果错误时，管理员可以 reset generated outputs 后重新提取。

5. 技术实现

5.1 Server actions

Action	职责
reserveAIPdfSourceUpload	校验文件元信息，创建 import_batches 和 pending import_batch_assets，返回 signed upload 信息。
finalizeAIPdfSourceUpload	确认对象已上传，检查 PDF 页数和大小，标记 source_pdf asset ready。
cancelAIPdfSourceUpload	上传失败或超时时按 uploadAttemptId 清理 pending asset。
deleteAIPdfSource	安全删除 source PDF；运行中阻止，已导入保留 batch audit 信息。
startAIPdfExtraction	校验 batch 和 provider，申请 job lease，拒绝重复启动和不安全状态。
runQueuedAIPdfExtraction	按 jobId 执行 leased extraction，推动服务端处理并写入 summary。
resetAIPdfImportOutputs	删除本批次已生成 draft outputs，用于错误结果重跑前恢复。
getAIPdfImportStatus	返回 batch、assets 和 summary，用于前端轮询与状态面板。

5.2 AI 输出规范化

- 顶层数组会被转换为 { questions: [...] }。
- items 字段可映射为 questions。
- question_type 会把 multiple_choice、choice question、multiple 等归一化为 mcq。
- difficulty_rating 会转为数字并限制在 0 到 1000。
- tag_names、tag_slugs、new_tag_names、page_refs 支持 scalar 到 array 的归一化。
- 缺失 content_html 时会从 content_source 生成简单 HTML；缺失 title 时用 question_code 和内容片段兜底。
- content_source 和 solution_source 优先保留为可编辑 Markdown + LaTeX，简单数学文本会生成内部 math HTML。

5.3 Prompt 和 provider 错误处理

- Prompt 要求模型优先输出 clean Markdown + LaTeX source，inline math 使用 $...$，display math 使用 $$...$$。
- Prompt 要求 content_html 避免直接写 raw dollar math；如果 HTML 包含数学，应使用 data-type inline/block math 节点。
- Prompt 要求模型复用 active tags，必要时创建 draft knowledge tag，不使用 archived tags。
- provider 返回 HTML 错误页时，系统压缩为 provider timeout 或 HTTP error 摘要。
- Cloudflare 524 等超时错误会显示为上游 provider 或网关超时，而不是完整 HTML 页面。

5.4 前端状态控制

- 前端 operation 带 id 和 batchId，异步回写前检查 owner，减少多个操作互相覆盖状态文本。
- 上传阶段加入超时和取消处理，避免文件选择器长期处于不可恢复状态。
- 提取阶段显示 loader、phase label、detail、warnings、error 和轮询日志。
- source list 根据 batch status 快照更新，而不是只依赖启动 action 的一次返回值。

5.5 编辑器和渲染

- QuestionHtmlEditor 的 HTML 模式初始化为 content_html，符合 Advanced HTML 语义。
- RichHtml 在 useLayoutEffect 中扫描 text node，将 legacy raw $...$ 转成 data-type inline-math 节点，再交给 KaTeX。

- 扫描跳过 code、pre、textarea、script、style 和既有 math 节点。
- 对明显数学尾部的奇数 dollar 做保守补全，修复 AI 常见的 $x = 漏闭合情况。

6. 文件变更

文件	改动摘要
next.config.ts	移除不稳定的 serverActions bodySizeLimit 配置。
src/app/admin/imports/pdf/actions.ts	AI PDF source 上传、删除、reset、lease extraction、status actions。
src/app/admin/imports/pdf/page.tsx	PDF import 页面接入 sources、provider 和 status 数据。
src/components/ai-pdf-import-panel.tsx	上传、source 管理、提取轮询、运行状态和错误展示。
src/lib/ai-pdf-import/schema.ts	AI JSON 容错 schema 和字段 normalization。
src/lib/ai-pdf-import/service.ts	prompt、progress summary、normalized import JSON、crop attachment。
src/lib/ai-providers/chat.ts	provider 调用、JSON repair、timeout/HTML error 清理。
src/components/rich-html.tsx	legacy raw dollar math hydration。
src/components/question-html-editor.tsx	Advanced HTML 显示真实 content_html。
question-source-files 相关文件	普通题目 PDF source 上传校验和失败清理。
src/app/admin/review/page.tsx	review 页面展示 AI/import source 上下文。

7. 验证结果

- npm run lint：通过。
- npm run build：通过。
- 浏览器验证 /admin/questions：展开 76 Local Minimum of a Function，Advanced HTML 显示真实 ...$...$... HTML。
- 浏览器验证 /admin/questions：同一题 Preview 已渲染 KaTeX，raw $...$ 不再外露。
- 浏览器控制台：渲染修复后未发现新的 error/warn。
- PDF 报告渲染检查：已抽查页面，中文正常，无明显截断、重叠或乱码。

8. 风险和后续工作

- 当前 leased job 比 setTimeout 稳定，但生产环境最终仍建议接入持久 worker queue，以处理 serverless 回收和长任务重试。
- reset generated outputs 涉及数据库和 storage 两类资源，本轮已加 guard；后续建议将数据库部分收敛到 RPC 或事务。
- 旧题目的 content_source_format 可能仍是 html；预览和公开展示已兼容，但自动迁移为 Markdown + LaTeX 需要单独脚本和人工抽查。
- AI crop placeholder 目前不是强制要求，因为 question_assets 能在题目下方展示；如后续需要精确内联排版，应在 Review 阶段强制检查 placeholder。
- provider 524 属于上游网关或模型超时风险，系统能展示失败原因，但无法在应用层完全消除；建议针对大 PDF 增加页数、大小和 provider 能力提示。

9. 结论

本次变更将 PDF AI Import 接入现有内容生产体系。source 文件可管理，提取过程可观察，AI 输出可修复，失败结果可恢复，最终题目仍由 Review Drafts 和人工发布把关。该功能适合作为后续内容团队大量录入题目前的导入入口，不作为绕过审核链路的自动发布工具。